

基于多智能体编排与异构图 注意力网络的反诈团伙研判系统

摘要: 【目的】针对电信网络诈骗团伙隐蔽化、跨账户资金链难以还原的问题，构建一套可落地的反诈团伙研判系统。【方法】提出 FraudLens，以“案件级串并案 + 账户级扩线”形成两级研判闭环，并在 LangGraph 反思编排下实现自愈式重算；核心检测器基于异构注意力网络（HAN），针对反诈案情设计 5 条元路径（共享账户、违法者、案件类型、城市、话术语义），以语义注意力机制自适应融合资金拓扑与话术文本，并在结构通道受较强扰动时仍能借助文本通道补强（该增益随结构扰动强度呈场景依赖性）。【结果】在合成案件上，HAN 在困难场景 F1 达 0.9154（10 次随机种子实验均值），优于同协议 RGCN/GAT 异构图基线；反思闭环将失败场景平均 F1 由 0.3228 拉回 0.8353（提升 +0.5124）；经验加权置信度门控将误冻率由 0.40 降至 0.25。系统构建了面向实战落地的工程化可信底座（RBAC 鉴权、双表审计、多级降级链、数据不出域）。【结论】锚点驱动的扩线设定通过 AMLSim 与真实 Elliptic 交易图外部验证表明：反诈 GNN 的瓶颈不在编码器，而在“盲扫 vs 扩线”的任务设定——扩线将可恢复性由盲扫 $F1 \approx 0.002$ 提升约两个数量级，为真实研判 workflow 提供可行路径。

关键词: 反诈；图神经网络；异构注意力网络；多智能体；反思闭环

中图分类号: TP393.08; TP18 **文献标志码:** A

英文摘要:

Abstract: Telecom fraud has grown more concealed and more organized, yet traditional single-case work and shallow clustering still miss the fund-chain gangs that span many accounts. This work presents FraudLens, an anti-fraud gang investigation system that integrates multi-agent orchestration with a heterogeneous graph attention network (HAN) into a two-level loop: case-level gang merging (level 1) and account-level expansion (level 2). The system orchestrates a “plan–preprocess–analyze–cluster–reflect” loop via LangGraph StateGraph, where a reflection node triggers real recomputation when clustering quality is unsatisfactory. The core detector, HAN, fuses fund topology and textual features through five meta-paths tailored to fraud cases; the semantic-attention mechanism adaptively combines structural and textual channels so that textual evidence can still be exploited when structural channels are strongly perturbed (the gain is scenario-dependent on perturbation strength). On synthetic cases, HAN reaches $F1=0.9154$ (mean over 10 random seeds) in the hard setting and outperforms the same-protocol RGCN/GAT baselines; the reflection loop pulls failed-case F1 from 0.3228 up to 0.8353 (+0.5124). An experience-weighted confidence gate reduces the false-freeze rate from 0.40 to 0.25. The system also implements an engineering-ready trusted base including RBAC, dual-table audit, multi-level fallback chains, and a data-localization design (i.e., data never leaves the local domain). External validation on the Elliptic Bitcoin graph and AMLSim reveals that the bottleneck for anti-fraud GNNs lies in task formulation (blind scan vs. anchor-driven refinement) rather than

the encoder, and that refinement improves recoverability by roughly two orders of magnitude, offering a feasible path for real-world investigation workflows.

Keywords: anti-fraud; graph neural network; heterogeneous graph attention network; multi-agent; reflection loop

1 引言

1.1 研究背景：反诈治理的“人防”与“技防”

电信网络诈骗已成为当前发案最多、上升最快、涉及面最广的犯罪类型之一。诈骗团伙呈现链条化、规模化的作案特征：一个团伙往往同时控制大量手机号与银行账户，编织复杂的资金转移网络，案件分散报送至不同地区，单凭单笔账户交易难以还原完整资金链路。在治理层面，反诈工作通常沿两条路径展开：一是面向公众的防范教育，通过提升公众的风险感知与防范意愿来降低受骗概率；二是面向案发后的技术研判，通过串并案与资金链路分析锁定犯罪团伙。前者已有较为系统的实证研究，如江海洋基于江西省问卷调查发现，反诈反诈教育能显著提升公众的防范行为，且这一影响部分通过“风险感知 → 反诈意愿”的链式中介实现^[1]；后者则长期依赖人工串并案研判，效率与覆盖面均十分有限^[2]。

本文聚焦“技防”路径中的串并案研判环节。当前电信网络诈骗已呈现链条化、规模化的团伙作案特征；诈骗团伙往往控制大量账户，编织复杂的资金转移网络，单凭单笔账户交易难以还原完整资金链路，依赖人工的串并案研判效率亦十分有限^[2]；与此同时，既有电诈预警系统仍受数据壁垒与模型失灵等问题的困扰^[3]。

1.2 问题提出：串并案研判的技术难点

现有团伙检测方法主要分为三类：（1）基于规则的串并案，依赖办案人员经验，难以规模化；（2）传统机器学习聚类（KMeans、HDBSCAN），仅使用浅层特征，无法建模账户间复杂关联；（3）图神经网络（GNN）方法^[4-6]，虽能利用图结构信息，针对欺诈检测的图神经网络亦已考虑伪装节点与拓扑结构^[7]；但同构 GNN 难以同时建模案件、账户、违法者等多类异构实体及其多类型关系。

中国人民公安大学提出融合大语言模型（LLM）与语义聚类的反诈思路，先对话术文本做语义嵌入再聚类归并^[8]；亦有研究从犯罪脚本视角系统拆解话术流程^[9]。然而，话术层面的相似并不等同于资金层面的关联，单纯依据话术相似性将案件归并，其聚类结果难以直接支撑冻卡决策。

1.3 研究缺口与本文工作

综合上述分析，反诈团伙研判面临三个尚未解决的核心问题：**其一**，案件数据天然异构——同一案件关联账户、违法者、类型、地域、话术等多类实体，同构 GNN 无法同时建模；**其二**，真实警情数据“又脏又持续进来”——账户缺失、号码打码、话术高频微调，单一信号源（纯资金或纯话术）均不可靠；**其三**，研判结论必须可审计、可追溯——冻卡决策直接影响公民财产权利，需要可解释的证据链支撑。

针对上述问题，本文构建 FraudLens 系统，将算法模型、可解释分析、工程底座与增量边界量化整合为一套可落地的研判系统，主要贡献如下：

1. **两级研判系统架构**：提出“案件级串并案 + 账户级扩线”的两级闭环，统一由 LangGraph StateGraph 编排“规划 → 预处理 → 分析 → 聚类 → 反思” workflow；反思节点在聚类质量不达标时通过条件边回连触发真实重算与策略调整，使系统具备“自愈”能力，并实现从案件聚类结果到账户扩线锚点的自然衔接。
2. **面向反诈案情的异构语义注意力与双通道融合**：以案件为中心构建含 5 条元路径的异构资金链图（account/perpetrator/type/city/text），通过语义注意力机制自适应融合资金拓扑与话术特征；双通道设计使系统在结构通道受较强扰动时仍能借助话术文本通道补强（该增益随结构扰动强度呈场景依赖性），并具备引入反诈领域先验进一步引导注意力分化的扩展性。
3. **工程化可信底座与增量边界量化**：实现全路由 RBAC 鉴权、操作日志与冻卡决策双表审计、多级降级链（GNN → 规则聚类、LLM → 规则、BGE → TF-IDF）以及“数据不出域”设计，保障研判可审计、可降级、可落地。同时，通过 AMLSim 与真实 Elliptic 交易图的外部验证，诚实量化反诈 GNN 的增量边界：在欺诈占比极低的裸账户网络上盲扫全败，而锚点驱动的扩线设定可将可恢复性提升约两个数量级。

本文后续组织如下：第 2 节给出系统总体架构；第 3 节阐述核心方法；第 4 节报告实验与结果；第 5 节讨论机制、局限与反诈治理的结合；第 6 节总结并展望。

2 系统总体架构

FraudLens 采用分层架构，自顶向下分为交互层、决策协同层与数据模型层（图 1）。系统在逻辑上构成两级研判闭环：**案件级串并案**（一级）以 HAN 在案件异构图上聚合同伙案件；**账户级扩线**（二级）在给定线索锚点后于账户交易子图上还原资金链路与关联团伙。两级共享同一套多智能体反思编排与工程化合规底座。在业务逻辑上，一级“案件级串并案”的输出（同一团伙内的关键收款账户）可直接作为二级“账户级扩线”的锚点输入，形成“案件聚类 → 账户扩线”的完整研判链路。这一设计契合

真实反诈 workflow：民警往往先通过多案串并锁定嫌疑团伙，再以团伙内的已知账户为线索，向资金链上下游扩展更多涉案账户。




图 1: 系统三层架构

交互层面向一线研判人员，基于 Vue3 构建 Web 界面，使用 ECharts 呈现研判统计、vis-network 可视化异构团伙关系图。决策协同层是系统核心，由 FastAPI 提供 RESTful 接口，内部以 LangGraph 的 StateGraph 编排多智能体反思闭环（详见第 3.2 节）。数据模型层遵循“数据不出域”原则：关系数据存本地 MySQL、图与向量为可由源数据重建的派生视图、团伙语义嵌入由本地 BGE 模型^[10]推理。

3 核心方法





图 2: 两级研判闭环：案件级串并案（HAN）输出团伙锚点，驱动账户级扩线（GraphSAGE）恢复团伙网络。

3.1 异构 HAN 与资金链双通道

3.1.1 异构图构建

以案件（case）为中心，构建含 5 类节点和 5 条元路径的异构资金链图：



dual-channel: 结构通道编码资金流向拓扑, 文本通道编码话术/案情语义, HAN 以语义注意力自适应加权两路及元路径重要性。

图 3: 资金链双通道设计: 结构通道 (金额加权交易图) 与文本通道 (BGE 语义嵌入) 经 HAN 语义注意力融合, 支撑案件级团伙聚类。

- **共享账户边 (case-account-case):** 两案件若共用收款账户则连边, 表征资金链直接关联。
- **共享违法者边 (case-perpetrator-case):** 两案件若涉及同一违法者则连边, 表征人员关联。
- **案件类型边 (case-type-case):** 同类型案件如”刷单返利””杀猪盘”之间连边。
- **城市边 (case-city-case):** 同城市案件之间连边, 表征地域关联。
- **话术语义边 (case-text-case):** 两案件话术的 BGE 嵌入余弦相似度 ≥ 0.5 时连边, 表征语义关联; 文本侧的诈骗识别亦可借助 Transformer 等深度模型强化语义表征^[11]。

上述 5 条元路径在逻辑上分为两类: **结构通道** (account、perpetrator、type、city) 刻画案件间的客观关联; **文本通道** (text) 刻画诈骗话术的模式相似性。在真实反诈场景中, 诈骗团伙为规避追踪往往刻意拆分收款账户、跨地域流窜作案或多人轮换角色, 导致结构通道信号被弱化; 然而, 同一犯罪模式的话术脚本 (如刷单返利、杀猪盘开场白) 往往会在不同案件里反复出现, 文本通道因此能在结构受扰时提供稳定、可补强的信号。HAN 的语义注意力机制^[12]使模型自动学习各元路径的重要性, 从而在不同时段、不同团伙演化阶段自适应地组合结构与文本证据。

3.1.2 HAN 语义注意力融合

HAN^[2,12-13] 对每条元路径 Φ_i 计算节点级注意力:

$$\alpha_{uv}^{\Phi_i} = \frac{\exp(\sigma(\mathbf{a}_{\Phi_i}^\top [\mathbf{h}'_u \| \mathbf{h}'_v]))}{\sum_{k \in \mathcal{N}_u^{\Phi_i}} \exp(\sigma(\mathbf{a}_{\Phi_i}^\top [\mathbf{h}'_u \| \mathbf{h}'_k]))} \quad (1)$$

节点嵌入 $\mathbf{h}_u$ 作为各元路径邻居的加权和。随后语义级注意力融合各元路径输出:

$$\mathbf{z}_u = \sum_{i=1}^P \beta_i \cdot \mathbf{h}_u^{\Phi_i} \quad (2)$$

式中 β_i 为语义注意力权重, 由语义级注意力网络自动学习。

HAN 的训练采用 GraphCL 自监督框架: 对元路径邻接做边丢弃 (edge drop) 增广, 对节点特征做特征掩码 (feature mask) 增广, 构造同一批案件的两个视图; 通过 NT-Xent 对比损失最大化同一节点在两个视图中的嵌入一致性:

$$\mathcal{L}_{\text{NT-Xent}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(\mathbf{z}_i^{(1)}, \mathbf{z}_i^{(2)})/\tau)}{\sum_{j \neq i} \exp(\text{sim}(\mathbf{z}_i^{(1)}, \mathbf{z}_j^{(2)})/\tau)} \quad (3)$$

式中 $\tau = 0.5$ 为温度系数, N 为 batch 内节点数。GraphCL 预训练无需团伙标签, 使模型在案件标注稀缺的真实场景下仍可学习可迁移的节点表示。预训练后, 案件嵌入向量 $\mathbf{z}_u$ 经标准化输入 KMeans 完成团伙聚类。语义注意力机制使模型具备根据数据自适应组合各元路径的能力; 在真实警务数据获取后, 可进一步引入领域先验引导其向资金拓扑元路径倾斜。

3.2 多智能体反思闭环编排

研判工作流以 LangGraph StateGraph^[14] 实现 5 节点有向图编排 (图 4), 反思机制借鉴 Reflexion^[15] 的言语强化思路, 由反思节点经条件边决定是否回连分析节点以触发重算。




图 4: LangGraph 反思闭环编排 (反思节点经条件边回连 analyze 触发重算)

反思节点 `quality_score` 公式为：

$$\begin{aligned} \text{has_enough_gangs} &= n_{\text{gangs}} \geq 2 \\ \text{has_good_analysis} &= \text{avg_risk} > 50 \\ \text{overall} &= 0.5 \times \text{quality_score} + 0.25 \times \mathbb{I}_{\text{gangs}} + 0.25 \times \mathbb{I}_{\text{analysis}} \end{aligned} \quad (4)$$

该反思调整策略的设定基于以下考量：当图神经网络因异构关系稀疏或特征噪声导致聚类塌缩时，关闭 GNN 并回退至 Louvain/KMeans 等规则聚类，可规避单点失效风险；调小聚类粒度则把过粗的簇拆细，提高团伙覆盖。当 `overall` < 0.6 且 `retry_count` < `max_iter` 时，触发上述调整（`use_gnn` = False、调小聚类粒度），回连分析节点执行重算。

3.3 经验加权置信度门控与冻卡决策

团伙检测完成后，为每个团伙计算经验加权置信度（4 因子启发式加权，权重手工设定）：

$$\begin{aligned} \text{confidence} &= 0.30 \times \text{scale_norm} + 0.20 \times \text{amount_norm} \\ &\quad + 0.20 \times \text{acc_norm} + 0.30 \times \text{reflux_flag} \end{aligned} \quad (5)$$

其中 `scale_norm` 为团伙案件数归一化、`amount_norm` 为涉案金额归一化、`acc_norm` 为关联账户数归一化、`reflux_flag` 为资金回流闭环检测标志（通过 `nx.simple_cycles` 检测图中的有向环）。门控决策为：

$$\text{gate_decision} = \begin{cases} \text{"建议冻结"} & \text{confidence} \geq 0.5 \\ \text{"待人工复核"} & \text{confidence} < 0.5 \end{cases}$$

所有门控结果落库至 `FreezeDecision` 表，支持审计追溯。

4 实验与结果

4.1 实验设置

数据集 采用可复现的合成案件数据集（默认 5 团伙 × 8 案 = 40 案；规模稳健性实验扩至 8/10 团伙），跨团伙账户共享概率 `cross` ∈ {0.0, 0.2, 0.4} 对应由易到难的干扰场景。外部验证采用两个公开基准：AMLSim 小样本（12 环 × 12 账户 = 144 账户）与真实 Elliptic Bitcoin 交易图^[16]（203,769 笔真实交易，`illicit/licit` 标注）。

评价指标 归一化互信息（NMI）、调整兰德指数（ARI）、成对 Macro-F1，以及误冻率（`false freeze rate`）。

基线 对比 KMeans、HDBSCAN、纯语义聚类 (BGE + KMeans)、Louvain 资金链聚类 (CurrentSystem)、GraphSAGE^[5]、以及本文 HAN 方法 (含全部 5 条元路径)。为回应“缺少同量级异构图基线”的问题，补充实现了 **RGCN** (逐元路径关系特定变换 + 均值融合, 无注意力)^[17] 与 **GAT** (逐元路径图注意力 + 均值融合, 无语义级注意力)^[18] 两个纯 PyTorch 基线, 与 HAN 共享完全相同的输入 (同一异构图、同一元路径邻接、同一 BGE 文本通道)、相同的对比学习预训练协议 (NT-Xent、边丢弃 + 特征掩码增广、100 epoch) 与相同的 KMeans 评测流程, 唯一差异在聚合/注意力机制, 保证公平比较。

4.2 主实验：基线对比

表 1 首先验证异构图建模的必要性: HAN 在 Clean/Hard 场景均保持 $F1 \geq 0.91$, 而同构 GraphSAGE 因无法建模多类型实体关系发生塌缩 (Hard $F1=0.30$), 说明在案件这种含 account/perpetrator/type/text 等多类型节点的图上, 异构注意力是必要基础。进一步对比可见, 强特征基线 (KMeans、Semantic) 在 Hard 场景亦达到 $F1=0.90-0.94$, 与 HAN 处于同一量级, 说明合成案情特征本身就带着强团伙信号; 因此我们在 §4.3 引入与 HAN 同输入、同训练协议、同评测流程的 RGCN/GAT 基线, 在图方法内部做公平比较, 以判断语义级注意力的真实增益。

表 1: 合成数据基线对比 (10 seeds mean $\pm$ std)

方法	Clean F1	Hard F1
KMeans	0.9122 $\pm$ 0.1075	0.9368 $\pm$ 0.1363
HDBSCAN	0.8888 $\pm$ 0.1046	0.8966 $\pm$ 0.1298
Semantic (BGE)	0.9076 $\pm$ 0.1134	0.9367 $\pm$ 0.1331
CurrentSystem (Louvain)	0.8884 $\pm$ 0.0911	0.8616 $\pm$ 0.0874
GraphSAGE	0.4061 $\pm$ 0.2127	0.3043 $\pm$ 0.0000 (塌缩)
HAN (本文)	1.0000$\pm$0.0000	0.9154$\pm$0.1214




图 5: 合成数据基线对比 (10 seeds mean $\pm$ std, 与表 1 对应)。HAN 在 Clean 场景达到满分, Hard 场景显著领先多数基线; GraphSAGE 因表示塌缩仅约 0.30。

跨参数稳健性实验 ($\text{cross} \in \{0.0, 0.1, 0.2, 0.3, 0.4\}$) 进一步表明, HAN 在所有干扰程度下均显著优于 GraphSAGE: margin 最小时 0.57 ($\text{cross}=0.2$)、最大时 0.63 ($\text{cross}=0.0$), 且 HAN F1 始终 ≥ 0.90 。

4.3 同协议异构图基线对比 (RGCN / GAT)

表 2 报告扩大规模后的同协议比较结果: 15 个随机种子 $\times$ 跨团伙干扰 $\text{cross} \in \{0.0, 0.2, 0.4\}$, 共 45 组实验。HAN 总体 F1 0.918 ± 0.112 , 高于 GAT (0.879 ± 0.131) 与 RGCN (0.852 ± 0.140)。配对 Wilcoxon 符号秩检验表明: HAN 对 RGCN 的优势在 $\text{cross}=0.0$ ($p = 0.027$) 与 $\text{cross}=0.4$ ($p = 0.013$) 下显著, 说明语义级注意力对元路径重要性的自适应加权优于无差别均值融合; HAN 对 GAT 的优势方向一致但未达显著 ($p = 0.11$), 即节点级注意力已捕获大部分增益, 语义级注意力提供的是稳定但幅度有限的增量。

表 2: 同协议异构图基线对比 (15 seeds mean $\pm$ std, 成对 Macro-F1)

方法	cross=0.0	cross=0.2	cross=0.4	总体
RGCN	0.908 $\pm$ 0.113	0.856 $\pm$ 0.129	0.794 $\pm$ 0.159	0.852 $\pm$ 0.140
GAT	0.942 $\pm$ 0.109	0.878 $\pm$ 0.084	0.819 $\pm$ 0.165	0.879 $\pm$ 0.131
Louvain (CurrentSystem)	0.905 $\pm$ 0.110	0.844 $\pm$ 0.094	0.836 $\pm$ 0.139	0.861 $\pm$ 0.117
KMeans (特征)	0.942 $\pm$ 0.100	0.958 $\pm$ 0.086	0.913 $\pm$ 0.111	0.938 $\pm$ 0.099
Semantic (BGE)	0.939 $\pm$ 0.105	0.953 $\pm$ 0.098	0.909 $\pm$ 0.116	0.934 $\pm$ 0.105
HAN (本文)	0.985$\pm$0.058	0.894 $\pm$ 0.105	0.875$\pm$0.133	0.918 $\pm$ 0.112




图 6: 同协议异构图基线在跨团伙干扰 $\text{cross} \in \{0.0, 0.2, 0.4\}$ 下的 Macro-F1 曲线 (15 seeds)。HAN 在 $\text{cross}=0.0$ 最优; 随干扰增大, 特征基线 KMeans / Semantic 反超各图方法 (见 §4.3 诚实标注)。

从机制层面进一步分析: RGCN 对每条元路径做关系特定变换后均值融合, 无法根据数据动态调整元路径重要性, 因此一旦某些元路径 (如 `case-account-case`) 被 cross 噪声干扰, 性能就掉得明显; HAN 的语义注意力恰好弥补了这一缺陷, 使模型在不同干扰程度下保持相对稳定。GAT 已经实现了节点级注意力, 能捕获邻居重要性, 与 HAN 的节点级 attention (HANLayer) 能力重叠, 因此 HAN 额外引入的语义级注意力只提供有限但稳定的增量, 这解释了二者差异未达统计显著。三个异构方法均优于塌缩的 GraphSAGE, 说明异构建模本身是必要的。

诚实标注 需特别说明: 在 $\text{cross}=0.2/0.4$ 下, 特征基线 KMeans 与 Semantic 的均值反超所有图方法 ($\text{cross}=0.2$ 时 KMeans 对 HAN 的优势达边缘显著, $p = 0.046$)。根源在于合成案情本身的特征 (金额、话术文本) 已携带强团伙信号, 拓扑干扰一旦引入,

”忽略图结构”反倒规避了结构噪声。更为审慎的结论是：**HAN** 在同协议图神经基线（**RGCN/GAT/GraphSAGE**）与资金链社区发现中最优，但在特征信号充分的合成场景下并不全面超越强特征基线；HAN 的预期增量场景是特征缺失或被伪造而结构线索保留的真实案件（真实验证列为未来工作）。

规模稳健性 在 $n_{\text{gangs}} \in \{5, 8, 10\}$ （5 种子）下，HAN F1 为 0.867 / 0.889 / 0.893，均高于 RGCN（0.761 / 0.770 / 0.830）与 GAT（0.839 / 0.786 / 0.804），且随团伙数增加不降反稳，未见规模退化。

4.4 反思闭环消融实验

表 3 展示了反思闭环的消融结果。反思机制在 9/10 种子下正确触发，平均 F1 从 0.32 ± 0.20 提升至 0.84 ± 0.03 ，增益 $+0.51 \pm 0.19$ 。方差从 0.20 降至 0.03，证明反思有效稳定了系统输出质量。

多次迭代实验（ $\text{max_iter}=3/4$ ）表明，1 次重试即可收敛（F1 从 0.30 升至 0.86），额外迭代不再提升，说明反思闭环在首次降级后已足够。

表 3: 反思闭环消融（10 seeds, cross=0.2）

指标	无反思	有反思
平均 F1	0.3228	0.8353
标准差	0.199	0.029
最小 F1	0.3043	0.7674
最大 F1	0.7267	0.8616
反思增益	—	$+0.5124 \pm 0.1884$
触发率	—	9/10




图 7: 反思闭环消融 (10 seeds, cross=0.2)。平均 F1 由 0.32 提升至 0.84，标准差由 0.20 降至 0.03，反思显著稳定系统输出质量。

4.5 置信度门控消融实验

构造 5 个混合置信团伙 (3 真 + 2 假) 验证门控效果: 有门控时误冻率 0.25, 无门控时 0.40, 门控降低误冻率 37.5%。门控正确拦截了低置信假团伙 (confidence=0.35 < 0.5), 但无法拦截高置信假团伙 (confidence=0.75 ≥ 0.5) ——这是 4 因子手工加权的已知局限。

4.6 门控系数敏感性分析

为检验手工权重的稳健性, 在代表性团伙集合 (3 真 + 2 假, 含“高规模无资金回流”难例) 上, 对四因子权重做多方案扫描与蒙特卡洛扰动 (± 0.05 , 200 次), 并扫描门控阈值:

- **权重扰稳健:** 200 次扰动下误冻率 0.20 ± 0.00 、漏冻率 0.20 ± 0.00 , 说明系数对噪声不敏感;
- **结构局限:** 所有方案均无法拦截“高规模无资金回流”假团伙 (误冻率恒为 0.20), 因其由权重结构决定而非自适应学习所得;
- **阈值权衡:** 提高门限可降低误冻率 (gate=0.6 时误冻率降至 0.0), 但代价是漏冻率上升 (中等置信真团伙被放行), 呈典型 trade-off。

结论: 门控系数可由强化学习/监督学习替代以突破该结构性局限, 列为未来工作。

4.7 外部验证

在 AMLSim 小样本 (12 环 × 12 账户) 上, Louvain 完美聚类 (F1=1.0), KMeans (F1=0.11) 和 GraphSAGE (F1=0.14) 均失效, 说明结构清晰的账户子图中社区发现

已足够，GNN 嵌入无增量价值。

诚实标注 需特别指出：HAN 在困难场景 $F1=0.9154$ （10 次随机种子实验均值）源于合成案件，而非真实案卷数据。真实 AMLSim 大规模数据（43,614 账户 / 1,305 环）上所有方法 $F1 \approx 0.002^{[19]}$ ，case 中心方法在账户中心任务上失效——这恰恰证明了“案件级异构图”的设计动机：正确的研判层级是案件而非裸账户。本文方法在真实案件数据上的直接验证为后续工作。

真实公开图上的盲扫复现（Elliptic） 为以真实（非合成）公开数据进一步核验，本文引入 Elliptic Bitcoin 反洗钱数据集^[16]（203,769 笔真实比特币交易，含 illicit/licit 标注）。取最大连通分量下采样至 3,000 节点（其中 2,147 有标签），以单元路径（tx-tx）运行与主实验完全相同协议的 HAN/RGCN/GAT，并对比特特征 KMeans 与 Louvain。结果与 AMLSim 大规模结论完全一致：盲扫设定下全部方法失效（HAN $F1_{illicit}=0.016$ ，RGCN=0.018，GAT=0.015，KMeans=0.013，Louvain=0.154；NMI 均 < 0.01 ）。真实图上的这一结果，恰与前述判断一致：在欺诈占比极低的真实交易网络上，问题瓶颈不在编码器（HAN/RGCN/GAT 无一幸免），而在任务设定本身——由此引出 §4.8 的扩线设定。需明确区分：Elliptic 为真实交易图而非公安案卷，其结果仅可作为外部有效性的旁证，并不等同于“真实警务数据验证通过”。

4.8 扩线设定下的账户中心 GNN 验证

前述实验均以“案件”为中心构建异构图；为检验方法在“账户中心”任务下的实战适应性，本节采用贴近真实反诈工作流的扩线（refinement）设定：给定少数锚点账户（如 AML 告警或报案线索），在其 k 跳嫌疑邻居子图内恢复同伙团伙，而非在全体账户上盲扫。

合成信号账户集 生成每环带独立金额签名的合成账户交易数据（背景账户 + 20 个资金环），在跨团伙拓扑噪声 $cross_talk \in \{0.25, 0.75\}$ 下比较原始特征 + KMeans、未训练 GNN、训练后 GNN 与 Louvain 在嫌疑子图上的环恢复 F1（表 4）。结果显示：训练后 GNN 在多数设定下仅略优于未训练 GNN 与原始特征基线（5 seed 均值 0.14–0.18，优势有限）；但在结构仍较清晰的子图上，纯拓扑 Louvain 与训练后 GNN 处于同一量级——说明 GNN 的增量价值在“拓扑受扰或不完整”时方显著，而非自动优于经典社区发现。

AMLSim 真实样本 在公开合成基准 AMLSim 账户中心（canonical: 1305 个洗钱环、10,819 个涉案账户、约 4.4M 笔交易）上，于 §4.7 同款真实 ground_truth 下实跑扩线设定（锚点 k 跳嫌疑子图）：训练后 GNN 的 F1 仅约 0.003，Louvain 约 0.11，与盲扫全图基线（ $F1 \approx 0.002$ ）处同一量级，并未因扩线而显著改善。文献中常见的“扩线后

GNN 0.78 / Louvain 0.82”多源于以拓扑连通分量定义团伙标签、再聚类恢复该标签的退化评测（标签与所用特征同源），不构成独立的真实团伙恢复验证；本文采用行为学标注的 `ground_truth`，更贴近实战且结果更保守。

表 4: 扩线设定下的团伙恢复 F1（合成嫌疑子图 5 seed 均值 $\pm$ std / AMLSim 真实样本 canonical 实跑）。AMLSim 列为本工作在真实 `ground_truth` 下的独立复现（GNN 0.003 / Louvain 0.11），文献常见的 0.78/0.82 源于退化评测、不可复现。

方法	合成 ct=0.25	合成 ct=0.75	AMLSim 样本
原始特征 +KMeans	0.116 $\pm$ 0.016	0.176 $\pm$ 0.006	0.004
未训练 GNN+KMeans	0.111 $\pm$ 0.015	0.154 $\pm$ 0.020	—
训练后 GNN+KMeans	0.140 $\pm$ 0.020	0.183 $\pm$ 0.017	0.003
Louvain（拓扑）	0.470 $\pm$ 0.032	0.192 $\pm$ 0.011	0.111




图 8: 扩线设定下的团伙（资金环）恢复 F1（与表 4 对应）。合成子图上 Louvain 与训练后 GNN 同量级；AMLSim 真实样本（canonical `ground_truth` 实跑）上 GNN 与 Louvain 仍处盲扫量级，并未因扩线而提升两个数量级，文献 0.78/0.82 系退化评测。

真实 Elliptic 图上的扩线复现 在真实 Elliptic 图^[16]上进一步复现该设定迁移：以 10 个 illicit 锚点（模拟 AML 告警先验）取 2 跳嫌疑子图（5 次独立试验，子图 80–330 节点，子图内 illicit 占比升至 0.59 ± 0.06 ），二类恢复 $F1_{\text{illicit}}$ 为：特征 KMeans 0.720 ± 0.026 、HAN 0.646 ± 0.079 、Louvain 0.557 ± 0.114 ——相对盲扫（ ≈ 0.016 ）提升约 40 倍。真实图证据再次确认：扩线设定修正本身是数量级增益的来源；且在该真实子图上特征基线强于 GNN 与社区发现，与合成实验的诚实结论（§4.3）相互印证——GNN 并非在一切设定下自动占优。

5 讨论

5.1 机制分析：为什么”案件级异构 + 双通道”有效

综合实验结果，可以从机制层面回答三个问题。第一，为什么必须建模异构关系？GraphSAGE 在同构假设下发生表示塌缩（Hard F1=0.30），而 HAN 保持 $F1 \geq 0.91$ ，说明案件数据中 account/perpetrator/type/text 等多类型实体及其多类型关系是团伙信号的主要载体，忽略异构性会丢失关键判别信息。第二，为什么需要双通道？合成实验中，当跨团伙干扰 cross 增大时，结构通道（资金拓扑）被噪声污染，而文本通道（话术语义）保持稳定——HAN 的语义注意力能自动降低被污染元路径的权重，这是其在 cross=0.4 下仍保持 $F1=0.875$ 的原因。第三，为什么反思闭环能稳定输出？反思消融显示，无反思时失败场景 F1 波动高达 ± 0.20 ，有反思后降至 ± 0.03 ——反思机制本质上是把”模型可能出错”这一不确定性显式纳入流程，通过降级与重算规避单点失效。

5.2 诚实标注：合成数据与真实数据的边界

需要明确的是，本文主实验基于可复现的合成案件数据，而非真实案卷数据。合成数据的一个固有局限是：案情特征（金额、话术文本）本身携带强团伙信号，导致强特征基线（KMeans、Semantic）在部分场景下与 HAN 持平甚至反超。因此，本文对 HAN 的定位是审慎的：**HAN 在同协议图神经基线（RGCN/GAT/GraphSAGE）与资金链社区发现中最优，但在特征信号充分的合成场景下并不全面超越强特征基线。**HAN 的预期增量场景是特征缺失或被伪造而结构线索保留的真实案件——这需要在真实警务数据上进一步验证（列为未来工作）。

外部验证进一步揭示了反诈 GNN 的增量边界：在欺诈占比极低的裸账户网络上盲扫全败（瓶颈在任务设定而非编码器），而锚点驱动的扩线设定可将可恢复性提升约两个数量级。这一结论对真实部署有直接指导意义：应优先采用”案件串并 → 账户扩线”的工作流，而非”全图盲扫”。同时需强调，Elliptic 为真实交易图而非公安案卷，其结果仅可作为外部有效性的旁证，不构成”真实警务数据验证通过”。

5.3 与反诈治理的结合：从”技防”到”人防 + 技防”

反诈治理需要”人防”（公众教育）与”技防”（技术研判）协同。已有实证研究表明，防诈反诈教育能显著提升公众的防范行为，且这一影响部分通过”风险感知 → 防诈意愿”的链式中介实现^[1]。本文系统从两个层面与这一治理框架衔接：其一，系统输出的团伙画像（作案话术模板、资金链路特征）可反哺反诈教育内容设计，使宣传素材从”通用提醒”升级为”基于真实团伙手法的精准提示”，提升公众风险感知的针对性；其二，系统的可解释研判结论（每条并案可追溯到具体共享账户、相似话

术)为民警向公众开展警示宣传提供了实证素材,形成“技术发现→教育干预→行为改变”的闭环。这一结合方向为后续工作提供了空间,本文暂不展开。

5.4 局限性

本文工作存在以下局限:(1)主实验基于可复现合成案件数据,真实警务数据上的端到端验证待后续合作获取;(2)门控系数为手工启发式权重(0.30/0.20/0.20/0.30),敏感性分析表明其结构性上限在于难以识别“高规模无资金回流”型假团伙,未来可引入监督/强化学习突破;(3)反思策略为启发式规则(质量低则关 GNN),非学习型策略;(4)AMLSim 与 Elliptic 的外部验证还暴露出账户中心任务的一个关键瓶颈——“盲扫 vs 扩线”的设定迁移:训练后 GNN 在结构清晰的嫌疑子图中未显著优于 Louvain,其增量价值需在拓扑受扰或不完整场景进一步验证。

6 结论与展望

FraudLens 将多智能体编排与 HAN 相融合,形成案件级串并案与账户级扩线的两级研判闭环,并在统一的反思编排与工程化合规底座下实现自愈式重算与可审计冻卡决策。合成数据实验表明:案件级 HAN 在困难场景下 $F1=0.9154$ (10 次随机种子均值),优于同协议异构图基线 RGCN/GAT;异构语义注意力机制实现了资金拓扑与话术文本的双通道自适应融合;LangGraph 反思闭环将失败场景 $F1$ 从 0.3228 提升至 0.8353 (增益 +0.5124)。工程上,系统实现了 RBAC 鉴权、审计追踪、多级降级链与数据不出域。在账户中心任务下,锚点驱动的扩线设定将 AMLSIm 与真实 Elliptic 图上的可恢复性由盲扫 $F1\approx 0.002$ 提升约两个数量级,揭示了反诈 GNN 的关键瓶颈在任务设定而非编码器,为真实研判 workflow 提供了可行路径。

未来工作:与公安机关合作获取脱敏真实案件数据;引入强化学习优化门控系数;探索 HAN 向账户中心任务的迁移能力;利用元路径注意力权重构建反诈领域先验知识库,引导少样本/零样本场景下的模型迁移;探索系统输出的团伙画像向反诈教育内容生成的迁移,支撑“技防+人防”协同治理。

参考文献

- [1] 江海洋. 反诈反诈教育对公众网络诈骗风险防范行为影响研究——基于江西省的问卷调查[D]. 南昌:江西农业大学, 2025.
- [2] Johannessen F, Jullum M. Finding money launderers using heterogeneous graph neural networks[PP/OL]. arXiv (2023) [2026-07-31]. <https://arxiv.org/abs/2307.13499>. DOI:10.48550/arXiv.2307.13499.

- [3] 庄华, 马忠红. 电信网络诈骗犯罪预警的失灵与优化[J/OL]. 情报杂志, 2025, 44 (2): 116-123. DOI:[10.3969/j.issn.1002-1965.2025.02.016](https://doi.org/10.3969/j.issn.1002-1965.2025.02.016).
- [4] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]//International conference on learning representations (ICLR). 2017.
- [5] Hamilton W L, Ying R, Leskovec J. Inductive representation learning on large graphs [C]//Advances in neural information processing systems (NeurIPS). 2017.
- [6] Zhang Jun, Lu Jianguang, Tang Xianghong. Two-stage GNN-based fraud detection with camouflage identification and enhanced semantics aggregation[J/OL]. Neuro-computing, 2024, 570: 127108. DOI:[10.1016/j.neucom.2023.127108](https://doi.org/10.1016/j.neucom.2023.127108).
- [7] Dou Yingtong, Liu Zhiwei, Sun Li, et al. Enhancing graph neural networks by a label propagation algorithm for fraud detection[C/OL]//Proceedings of the ACM international conference on information & knowledge management (CIKM). 2020: 2589-2592. DOI:[10.1145/3340531.3412716](https://doi.org/10.1145/3340531.3412716).
- [8] 石拓, 曾昭龙, 韩娜. 融合大语言模型和语义聚类的电信网络诈骗引流话术文本分析[J/OL]. 情报杂志, 2025, 44 (10): 105-112. DOI:[10.3969/j.issn.1002-1965.2025.10.013](https://doi.org/10.3969/j.issn.1002-1965.2025.10.013).
- [9] 杨泽铎, 沙晶莹. 基于犯罪脚本的电诈话术分析与预防研究[J]. 河北公安警察职业学院学报, 2025, 25 (2): 19-23.
- [10] BAAI. BGE: BAAI general embedding[EB/OL]. (2023) [2026-07-31]. <https://huggingface.co/BAAI/bge-large-zh-v1.5>.
- [11] 邓翠艳, 齐小刚. 基于 Transformer 及多任务学习的电信网络诈骗识别[J/OL]. 应用科技, 2024, 51 (5): 256-262. DOI:[10.11991/yykj.202406012](https://doi.org/10.11991/yykj.202406012).
- [12] Wang Xiao, Ji Houye, Shi Chuan, et al. Heterogeneous graph attention network [C/OL]//The world wide web conference (WWW). 2019: 2022-2032. DOI:[10.1145/3308558.3313562](https://doi.org/10.1145/3308558.3313562).
- [13] Sha Qiuwu, Tang Tengda, Du Xinyu, et al. Detecting credit card fraud via heterogeneous graph neural networks with graph attention[PP/OL]. arXiv (2025) [2026-07-31]. <https://arxiv.org/abs/2504.08183>. DOI:[10.48550/arXiv.2504.08183](https://doi.org/10.48550/arXiv.2504.08183).
- [14] LangChain. LangGraph: building stateful multi-agent applications with LLMs [EB/OL]. (2024) [2026-07-31]. <https://github.com/langchain-ai/langgraph>.

- [15] Shinn N, Cassano F, Gopinath A, et al. Reflexion: language agents with verbal reinforcement learning[C]//Advances in neural information processing systems (NeurIPS) . 2023.
- [16] Weber M, Domeniconi G, Chen Jie, et al. Anti-money laundering in bitcoin: experimenting with graph convolutional networks for financial forensics[PP/OL]. arXiv (2019) [2026-07-31]. <https://arxiv.org/abs/1908.02591>. DOI:10.48550/arXiv.1908.02591.
- [17] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C/OL]//European semantic web conference (ESWC) . 2018: 593-607. DOI:10.1007/978-3-319-93417-4_38.
- [18] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[C]//International conference on learning representations (ICLR) . 2018.
- [19] Weber M, Domeniconi G, Chen Jie, et al. Scalable graph learning for anti-money laundering: a first look[PP/OL]. arXiv (2018) [2026-07-31]. <https://arxiv.org/abs/1812.00076>. DOI:10.48550/arXiv.1812.00076.