

基于多智能体编排与异构图注意力网络的反诈团伙研判系统

作者姓名及单位（楷体四号居中，投稿前替换）

摘 要：针对电信网络诈骗团伙隐蔽化、跨账户资金链难以还原的研判难题，本文提出 **FraudLens** 反诈团伙研判系统：以案件为中心构建含共享账户、违法者、案件类型、城市、话术五类关系的异构图，由异构注意力网络（HAN）自适应融合资金拓扑与话术文本，实现案件级串并案；以 **LangGraph** 反思编排实现聚类质量不达标时的自动重算；进一步提出共识伪标签半监督与增量匹配机制，缓解标签稀缺与案件持续流入带来的失效问题。合成案件实验表明，HAN 在困难场景 F1 达 0.9154，反思闭环将失败场景平均 F1 由 0.3228 拉回 0.8353；半监督机制在重噪场景将 F1 提升至 0.9487。

关键词：反诈；图神经网络；异构注意力网络；多智能体；半监督学习

引言

电信网络诈骗已成为当前发案最多、上升最快、涉及面最广的犯罪类型之一，团伙呈链条化、规模化特征，往往同时控制大量手机号与银行账户，编织复杂的资金转移网络；案件分散报送至不同地区，单凭单笔交易难以还原完整资金链路，依赖人工的串并案研判效率与覆盖面均十分有限^[1]，既有电诈预警系统仍受数据壁垒与模型失灵困扰^[2]。现有团伙检测方法主要分三类：基于规则的串并案依赖办案经验难以规模化；传统聚类（KMeans、HDBSCAN）仅用浅层特征，无法建模账户间复杂关联；图神经网络（GNN）^[3-5]虽能利用图结构，但同构 GNN 难以同时建模案件、账户、违法者等多类异构实体。中国人民公安大学提出融合大语言模型与语义聚类的反诈思路，先对话术做语义嵌入再聚类归并^[6]；然而话术相似并不等同于资金关联，单纯依据话术归并难以直接支撑冻卡决策。

针对上述问题，本文构建 **FraudLens** 系统，主要贡献为：其一，提出“案件级串并案+账户级扩线”的两级研判架构，统一由 **LangGraph** 反思编排驱动，聚类质量不达标时自动触发重算，具备自愈能力；其二，以案件为中心构建含五条元路径的异构图，由 HAN 语义注意力自适应融合资金拓扑与话术文本，使系统在结构通道受扰动时仍能借助文本通道补强；其三，提出共识伪标签半监督与增量匹配机制，缓解真实场景标签稀缺与案件持续流入导致的失效问题，并实现可审计的置信度门控冻卡决策。

一 相关工作

（一） 电信网络诈骗技防研判

反诈”技防”研究沿”预警—话术分析—聚类归并”演进。预警层面,庄华等指出既有电诈预警系统存在数据壁垒与模型失灵等结构性问题^[2];邓翠艳等以 Transformer 多任务学习强化文本侧诈骗识别^[7];石拓等融合大语言模型与语义聚类对话术引流文本聚类归并^[6],杨泽铎等从犯罪脚本视角系统拆解话术流程^[8]。上述工作聚焦文本单通道,尚未将话术相似性与资金拓扑证据联合建模,聚类结果难以直接支撑冻卡决策,这正是本文双通道设计的出发点。

（二） 图神经网络欺诈检测

图神经网络已成为欺诈检测的主流手段:GCN^[3]、GraphSAGE^[4]、GAT^[9] 依次提升同构图表示能力;欺诈领域进一步考虑伪装节点(CareGNN^[10])与语义聚合(CIAL^[5])。针对洗钱与信用卡欺诈,异构图建模被证明优于同构方案^[1,11],HAN 的语义注意力机制^[12]可自适应融合多类型关系。外部基准上,AMLSim 与 Elliptic^[13-14] 提供了大规模反洗钱评测数据,但其”账户中心、欺诈占比极低”的设定使盲扫类方法普遍失效,本文据此引入”扩线”任务设定加以验证。

（三） 多智能体与反思编排

安全运营领域 SOAR 将安全编排自动化与响应结合^[15-16],但缺乏对模型输出质量的显式反馈闭环。大语言模型智能体方面,Reflexion^[17] 通过言语强化让智能体在失败后自我改进;江颀等构建了基于大语言模型的多智能体自动渗透测试框架^[18];张豈明等以 LangGraph^[19] 编排教案生成智能体^[20]。本文借鉴反思范式,将”质量评估—策略调整—重算”显式纳入研判流程,形成可追溯的自愈闭环。

二 系统总体架构

FraudLens 采用分层架构,自顶向下分为交互层、决策协同层与数据模型层(图 1)。系统在逻辑上构成两级研判闭环:**案件级串并案**(一级)以 HAN 在案件异构图上聚合同伙案件;**账户级扩线**(二级)在给定线索锚点后于账户交易子图上还原资金链路与关联团伙。两级共享同一套多智能体反思编排与工程化合规底座。在业务逻辑上,一级”案件级串并案”的输出(同一团伙内的关键收款账户)可直接作为二级”账户级扩线”的锚点输入,形成”案件聚类→账户扩线”的完整研判链路。这一设计契合真实反诈 workflow:民警往往先通过多案串并锁定嫌疑团伙,再以团伙内的已知账户为线索,向资金链

上下游扩展更多涉案账户。




图 1: 系统三层架构

交互层面面向一线研判人员，基于 Vue3 构建 Web 界面，使用 ECharts 呈现研判统计、vis-network 可视化异构团伙关系图。决策协同层是系统核心，由 FastAPI 提供 RESTful 接口，内部以 LangGraph 的 StateGraph 编排多智能体反思闭环（详见第（二）节）。数据模型层遵循“数据不出域”原则：关系数据存本地 MySQL、图与向量为可由源数据重建的派生视图、团伙语义嵌入由本地 BGE 模型^[21]推理。

三 核心方法





图 2: 两级研判闭环: 案件级串并案 (HAN) 输出团伙锚点, 驱动账户级扩线 (GraphSAGE) 恢复同伙网络。

（一） 异构 HAN 与资金链双通道

1 异构图构建

以案件 (case) 为中心，构建含 5 类节点和 5 条元路径的异构资金链图：

- **共享账户边 (case-account-case)**：两案件若共用收款账户则连边，表征资金链直接关联。
- **共享违法者边 (case-perpetrator-case)**：两案件若涉及同一违法者则连边，表征人员关联。
- **案件类型边 (case-type-case)**：同类型案件如“刷单返利”“杀猪盘”之间连边。



dual-channel: 结构通道编码资金流向拓扑, 文本通道编码话术/案情语义, HAN 以语义注意力自适应加权两路及元路径重要性。

图 3: 资金链双通道设计: 结构通道 (金额加权交易图) 与文本通道 (BGE 语义嵌入) 经 HAN 语义注意力融合, 支撑案件级团伙聚类。

- **城市边 (case-city-case):** 同城市案件之间连边, 表征地域关联。
- **话术语义边 (case-text-case):** 两案件话术的 BGE 嵌入余弦相似度 ≥ 0.5 时连边, 表征语义关联; 文本侧的诈骗识别亦可借助 Transformer 等深度模型强化语义表征^[7]。

上述 5 条元路径在逻辑上分为两类: **结构通道** (account、perpetrator、type、city) 刻画案件间的客观关联; **文本通道** (text) 刻画诈骗话术的模式相似性。在真实反诈场景中, 诈骗团伙为规避追踪往往刻意拆分收款账户、跨地域流窜作案或多人轮换角色, 导致结构通道信号被弱化; 然而, 同一犯罪模式的话术脚本 (如刷单返利、杀猪盘开场白) 往往会在不同案件里反复出现, 文本通道因此能在结构受扰时提供稳定、可补强的信号。HAN 的语义注意力机制^[12]使模型自动学习各元路径的重要性, 从而在不同时段、不同团伙演化阶段自适应地组合结构与文本证据。

2 HAN 语义注意力融合

HAN^[1,11-12] 对每条元路径 Φ_i 计算节点级注意力:

$$\alpha_{uv}^{\Phi_i} = \frac{\exp(\sigma(\mathbf{a}_{\Phi_i}^\top [\mathbf{h}'_u \| \mathbf{h}'_v]))}{\sum_{k \in \mathcal{N}_u^{\Phi_i}} \exp(\sigma(\mathbf{a}_{\Phi_i}^\top [\mathbf{h}'_u \| \mathbf{h}'_k]))} \quad (1)$$

节点嵌入 $\mathbf{h}_u$ 作为各元路径邻居的加权和。随后语义级注意力融合各元路径输出:

$$\mathbf{z}_u = \sum_{i=1}^P \beta_i \cdot \mathbf{h}_u^{\Phi_i} \quad (2)$$

式中 β_i 为语义注意力权重, 由语义级注意力网络自动学习。

HAN 的训练采用 GraphCL 自监督框架：对元路径邻接做边丢弃（edge drop）增广，对节点特征做特征掩码（feature mask）增广，构造同一批案件的两个视图；通过 NT-Xent 对比损失最大化同一节点在两个视图中的嵌入一致性：

$$\mathcal{L}_{\text{NT-Xent}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(\mathbf{z}_i^{(1)}, \mathbf{z}_i^{(2)})/\tau)}{\sum_{j \neq i} \exp(\text{sim}(\mathbf{z}_i^{(1)}, \mathbf{z}_j^{(2)})/\tau)} \quad (3)$$

式中 $\tau = 0.5$ 为温度系数， N 为 batch 内节点数。GraphCL 预训练无需团伙标签，使模型在案件标注稀缺的真实场景下仍可学习可迁移的节点表示。预训练后，案件嵌入向量 $\mathbf{z}_u$ 经标准化输入 KMeans 完成团伙聚类。语义注意力机制使模型具备根据数据自适应组合各元路径的能力；在真实警务数据获取后，可进一步引入领域先验引导其向资金拓扑元路径倾斜。

（二）多智能体反思闭环编排

研判工作流以 LangGraph StateGraph^[19] 实现 5 节点有向图编排（图 4），反思机制借鉴 Reflexion^[17] 的言语强化思路，由反思节点经条件边决定是否回连分析节点以触发重算。




图 4: LangGraph 反思闭环编排（反思节点经条件边回连 analyze 触发重算）

反思节点 quality_score 公式为：

$$\begin{aligned} \text{has_enough_gangs} &= n_{\text{gangs}} \geq 2 \\ \text{has_good_analysis} &= \text{avg_risk} > 50 \\ \text{overall} &= 0.5 \times \text{quality_score} + 0.25 \times \mathbb{I}_{\text{gangs}} + 0.25 \times \mathbb{I}_{\text{analysis}} \end{aligned} \quad (4)$$

该反思调整策略的设定基于以下考量：当图神经网络因异构关系稀疏或特征噪声导致聚类塌缩时，关闭 GNN 并回退至 Louvain/KMeans 等规则聚类，可规避单点失效风险；调小聚类粒度则把过粗的簇拆细，提高团伙覆盖。当 $\text{overall} < 0.6$ 且 $\text{retry_count} < \text{max_iter}$ 时，触发上述调整（ $\text{use_gnn} = \text{False}$ 、调小聚类粒度），回连分析节点执行

重算。

(三) 经验加权置信度门控与冻卡决策

团伙检测完成后，为每个团伙计算经验加权置信度（4 因子启发式加权，权重手工设定）：

$$\begin{aligned} \text{confidence} = & 0.30 \times \text{scale_norm} + 0.20 \times \text{amount_norm} \\ & + 0.20 \times \text{acc_norm} + 0.30 \times \text{reflux_flag} \end{aligned} \quad (5)$$

其中 scale_norm 为团伙案件数归一化、 amount_norm 为涉案金额归一化、 acc_norm 为关联账户数归一化、 reflux_flag 为资金回流闭环检测标志（通过 `nx.simple_cycles` 检测图中的有向环）。门控决策为：

$$\text{gate_decision} = \begin{cases} \text{"建议冻结"} & \text{confidence} \geq 0.5 \\ \text{"待人工复核"} & \text{confidence} < 0.5 \end{cases}$$

所有门控结果落库至 `FreezeDecision` 表，支持审计追溯。

(四) 共识伪标签半监督

真实反诈场景中团伙标签稀缺，纯自监督表示在重噪或大案量下聚类质量下降（见第四节）。为此提出共识伪标签半监督机制：对同一批案件分别以资金链 Louvain 社区发现与话术 BGE-KMeans 聚类，仅当两路结果对某案件给出**严格一致**的簇归属时，才将该簇作为高置信锚点；锚点规模不足时自动沿更细粒度重新估计聚类数（自适应 k 重估），对超过全部案件数 25% 的“巨簇”整簇弃用，避免低分辨率合并污染标签（客观置信度门控）。随后以锚点监督微调 HAN 分类头，非锚点案件由模型输出泛化，即 **hybrid 出牌**：锚点案件用规则标签、非锚点案件用模型预测。该机制将“规则高置信结果 $\rightarrow$ GNN 泛化”固化为可落地的半监督管线，缓解了自监督目标与团伙发现任务不对齐的问题。

(五) 增量匹配

案件持续流入时全量重算成本高昂且滞后。系统维护团伙画像（账户池与 BGE 话术质心），新案到达时做双信号判定：

$$\text{match}(c, g) = \models [\text{share_account}(c, g) \wedge \text{sim}(\mathbf{e}_c, \mathbf{e}_g) \geq \tau] \quad (6)$$

其中 $\mathbf{e}_c$ 为案件话术嵌入， $\mathbf{e}_g$ 为团伙话术质心， $\tau = 0.7$ ；仅当资金共享与话术语义两个信号同时满足才并入既有团伙，宁缺毋滥；未匹配案件攒批后进入下一轮全量聚类。该机制在轻噪大规模场景可流式

补回被全量聚类过合并的团伙（见第四节）。

四 实验与结果

（一） 实验设置

数据集 采用可复现的合成案件数据集（按真实警情形态自建，非真实案卷），构建 5 类场景覆盖真实研判环境：**P0 干净**（5 团伙 $\times$ 8 案 = 40 案，无跨团伙干扰）、**P1 轻噪**（话术与账户含轻度噪声）、**P2 重噪**（强跨团伙账户共享干扰， $\text{cross} \in \{0.2, 0.4\}$ ）、**P3 大规模**（10 团伙 $\times$ 20 案 = 200 案）、**P4 碰撞**（团伙间话术与资金模式部分碰撞）、**P5 极端信号**（结构信号极弱）。跨团伙账户共享概率 $\text{cross} \in \{0.0, 0.2, 0.4\}$ 对应由易到难的干扰场景。外部验证采用两个公开基准：**AMLSim** 小样本（12 环 $\times$ 12 账户 = 144 账户）与真实 **Elliptic Bitcoin** 交易图^[14]（203,769 笔真实交易，illicit/licit 标注）。

评价指标 归一化互信息（NMI）、调整兰德指数（ARI）、成对 Macro-F1，以及误冻率（false freeze rate）。

基线 对比 KMeans、HDBSCAN、纯语义聚类（BGE + KMeans）、Louvain 资金链聚类（CurrentSystem）、GraphSAGE^[4]、以及本文 HAN 方法（含全部 5 条元路径）。为回应“缺少同量级异构图基线”的问题，补充实现了 **RGCN**（逐元路径关系特定变换 + 均值融合，无注意力）^[22] 与 **GAT**（逐元路径图注意力 + 均值融合，无语义级注意力）^[9] 两个纯 PyTorch 基线，与 HAN 共享完全相同的输入（同一异构图、同一元路径邻接、同一 BGE 文本通道）、相同的对比学习预训练协议（NT-Xent、边丢弃 + 特征掩码增广、100 epoch）与相同的 KMeans 评测流程，唯一差异在聚合/注意力机制，保证公平比较。

（二） 主实验：基线对比

表 1 首先验证异构图建模的必要性：HAN 在 Clean/Hard 场景均保持 $F1 \geq 0.91$ ，而同构 GraphSAGE 因无法建模多类型实体关系发生塌缩（Hard $F1=0.30$ ），说明在案件这种含 account/perpetrator/type/text 等多类型节点的图上，异构注意力是必要基础。进一步对比可见，强特征基线（KMeans、Semantic）在 Hard 场景亦达到 $F1=0.90-0.94$ ，与 HAN 处于同一量级，说明合成案情特征本身就带着强团伙信号；因此我们在 §（三）引入与 HAN 同输入、同训练协议、同评测流程的 RGCN/GAT 基线，在图方法内部做公平比较，以判断语义级注意力的真实增益。

表 1: 合成数据基线对比 (10 seeds mean $\pm$ std)

方法	Clean F1	Hard F1
KMeans	0.9122 $\pm$ 0.1075	0.9368 $\pm$ 0.1363
HDBSCAN	0.8888 $\pm$ 0.1046	0.8966 $\pm$ 0.1298
Semantic (BGE)	0.9076 $\pm$ 0.1134	0.9367 $\pm$ 0.1331
CurrentSystem (Louvain)	0.8884 $\pm$ 0.0911	0.8616 $\pm$ 0.0874
GraphSAGE	0.4061 $\pm$ 0.2127	0.3043 $\pm$ 0.0000 (塌缩)
HAN (本文)	1.0000$\pm$0.0000	0.9154$\pm$0.1214




图 5: 合成数据基线对比 (10 seeds mean $\pm$ std, 与表 1 对应)。HAN 在 Clean 场景达到满分, Hard 场景显著领先多数基线; GraphSAGE 因表示塌缩仅约 0.30。

跨参数稳健性实验 ($\text{cross} \in \{0.0, 0.1, 0.2, 0.3, 0.4\}$) 进一步表明, HAN 在所有干扰程度下均显著优于 GraphSAGE: margin 最小时 0.57 ($\text{cross}=0.2$)、最大时 0.63 ($\text{cross}=0.0$), 且 HAN F1 始终 ≥ 0.90 。

(三) 同协议异构图基线对比 (RGCN / GAT)

表 2 报告扩大规模后的同协议比较结果: 15 个随机种子 $\times$ 跨团伙干扰 $\text{cross} \in \{0.0, 0.2, 0.4\}$, 共 45 组实验。HAN 总体 F1 0.918 ± 0.112 , 高于 GAT (0.879 ± 0.131) 与 RGCN (0.852 ± 0.140)。配对 Wilcoxon 符号秩检验表明: HAN 对 RGCN 的优势在 $\text{cross}=0.0$ ($p = 0.027$) 与 $\text{cross}=0.4$ ($p = 0.013$) 下显著, 说明语义级注意力对元路径重要性的自适应加权优于无差别均值融合; HAN 对 GAT 的优势方向一致但未达显著 ($p = 0.11$), 即节点级注意力已捕获大部分增益, 语义级注意力提供的是稳定但幅度有限的增量。

表 2: 同协议异构图基线对比 (15 seeds mean $\pm$ std, 成对 Macro-F1)

方法	cross=0.0	cross=0.2	cross=0.4	总体
RGCN	0.908 $\pm$ 0.113	0.856 $\pm$ 0.129	0.794 $\pm$ 0.159	0.852 $\pm$ 0.140
GAT	0.942 $\pm$ 0.109	0.878 $\pm$ 0.084	0.819 $\pm$ 0.165	0.879 $\pm$ 0.131
Louvain (CurrentSystem)	0.905 $\pm$ 0.110	0.844 $\pm$ 0.094	0.836 $\pm$ 0.139	0.861 $\pm$ 0.117
KMeans (特征)	0.942 $\pm$ 0.100	0.958 $\pm$ 0.086	0.913 $\pm$ 0.111	0.938 $\pm$ 0.099
Semantic (BGE)	0.939 $\pm$ 0.105	0.953 $\pm$ 0.098	0.909 $\pm$ 0.116	0.934 $\pm$ 0.105
HAN (本文)	0.985$\pm$0.058	0.894 $\pm$ 0.105	0.875$\pm$0.133	0.918 $\pm$ 0.112




图 6: 同协议异构图基线在跨团伙干扰 $\text{cross} \in \{0.0, 0.2, 0.4\}$ 下的 Macro-F1 曲线 (15 seeds)。HAN 在 $\text{cross}=0.0$ 最优; 随干扰增大, 特征基线 KMeans / Semantic 反超各图方法 (见 § (三) 诚实标注)。

从机制层面进一步分析: RGCN 对每条元路径做关系特定变换后均值融合, 无法根据数据动态调整元路径重要性, 因此一旦某些元路径 (如 `case-account-case`) 被 cross 噪声干扰, 性能就掉得明显; HAN 的语义注意力恰好弥补了这一缺陷, 使模型在不同干扰程度下保持相对稳定。GAT 已经实现了节点级注意力, 能捕获邻居重要性, 与 HAN 的节点级 attention (HANLayer) 能力重叠, 因此 HAN 额外引入的语义级注意力只提供有限但稳定的增量, 这解释了二者差异未达统计显著。三个异构方法均优于塌缩的 GraphSAGE, 说明异构建模本身是必要的。

诚实标注 需特别说明: 在 $\text{cross}=0.2/0.4$ 下, 特征基线 KMeans 与 Semantic 的均值反超所有图方法 ($\text{cross}=0.2$ 时 KMeans 对 HAN 的优势达边缘显著, $p = 0.046$)。根源在于合成案情本身的特征 (金额、话术文本) 已携带强团伙信号, 拓扑干扰一旦引入, “忽略图结构” 反倒规避了结构噪声。更为审慎的结论是: **HAN** 在同协议图神经基线 (RGCN/GAT/GraphSAGE) 与资金链社区发现中最优, 但在特征信

号充分的合成场景下并不全面超越强特征基线：HAN 的预期增量场景是特征缺失或被伪造而结构线索保留的真实案件（真实验证列为未来工作）。

规模稳健性 在 $n_{\text{gangs}} \in \{5, 8, 10\}$ （5 种子）下，HAN F1 为 0.867 / 0.889 / 0.893，均高于 RGCN（0.761 / 0.770 / 0.830）与 GAT（0.839 / 0.786 / 0.804），且随团伙数增加不降反稳，未见规模退化。

（四） 共识伪标签半监督实验

表 3 报告六类场景下半监督机制与纯自监督、规则基线的对比。结果表明：**重噪场景（P2）半监督增益最大**，hybrid F1 由自监督 0.565 提升至 0.949（+0.38）；大规模场景（P3）hybrid 0.656 亦为该规模下最优，明显优于资金链规则 0.447 与特征 KMeans 0.540。这印证了机制设计动机：当结构通道被噪声污染或案件量增大时，规则单通道可靠性下降，”规则高置信结果 → GNN 泛化”的半监督管线成为最优路径。

表 3: 共识伪标签半监督实验（3 seeds mean±std，成对 Macro-F1）

场景	自监督	半监督（hybrid）	资金链规则	特征 KMeans
P0 干净	0.922±0.070	0.913±0.037	0.833±0.157	0.853±0.026
P1 轻噪	0.566±0.066	0.756±0.154	0.819 ±0.068	0.704±0.158
P2 重噪	0.565±0.083	0.949 ±0.050	0.821±0.142	0.499±0.078
P3 大规模	0.536±0.144	0.656 ±0.084	0.447±0.118	0.540±0.109
P4 碰撞	0.890±0.191	0.981 ±0.033	1.000 ±0.000	0.846±0.113
P5 极端信号	0.623±0.089	0.797 ±0.210	0.833 ±0.157	0.711±0.274

诚实标注 半监督并非在所有场景全面占优：干净场景（P0）下自监督 0.922 略高于 hybrid 0.913，锚点划分仍存在轻微分裂；轻噪场景（P1）下资金链规则 0.819 反超 hybrid 0.756。这说明规则聚类在信号干净时本就强大，半监督的增量价值主要体现在重噪、碰撞与大案量场景，而非替代一切基线。

（五） 增量匹配实验

表 4 报告增量匹配在两种代表性场景下的效果。轻噪大规模场景（P3）下，增量匹配 F1 0.609 反超全量重算 0.526（+0.083）：全量聚类在该场景将 10 个团伙过合并为 6 个，而流式匹配逐步补回剩余团伙；重噪场景（P2）下增量匹配低 6 分，源于约 25% 无账户案件在

单信号不满足时被门控拦截、攒批等待，属宁缺毋滥的主动取舍。总体上，”账户信号充足的数据上增量匹配效果不掉”的验收口径成立。

表 4: 增量匹配 vs 全量重算（成对 Macro-F1）

场景	全量重算	增量匹配	Δ	匹配精度
P2 重噪 40 案	0.6786	0.6185	-0.0601	0.857
P3 轻噪 200 案	0.5263	0.6089	+0.0826	0.580

（六） 可解释性分析

为验证 HAN 语义注意力是否按数据自适应分配元路径权重，在自监督协议下提取各干扰程度下的语义注意力权重（表 5，5 seeds 均值）。结构通道（账户、违法者、类型、城市）合计占据主要权重，文本通道保持非零权重，作为结构通道受扰时的保留信号；随跨团伙干扰增强，注意力在元路径间的分配趋于分散，模型主动降低被污染元路径的相对依赖。这一行为为”资金链可追溯 + 话术可解释”的研判结论提供了模型级依据。

表 5: 元路径语义注意力权重（自监督协议，5 seeds 均值）

元路径	cross=0.0	cross=0.2	cross=0.4
共享账户	0.235	0.226	0.211
共享违法者	0.224	0.231	0.238
案件类型	0.220	0.232	0.226
城市	0.215	0.216	0.218
话术语义（文本）	0.107	0.096	0.108

（七） 失败案例分析

极端场景暴露了机制边界并验证了门控的有效性。P5 极端信号下，某随机种子曾在默认聚类数下触发”共识锚点不足”门控、拒绝出牌，自适应 k 重估后恢复出牌，但绝对 F1 仍偏低且种子间波动大 (0.797 ± 0.210) ——门控有效阻止了脏锚点扩散，极端信号下的低值作为方法边界保留；P1 轻噪场景规则反超（表 3）同样说明，规则在信号干净时已足够，无需引入模型。上述失败模式均源于数据信号结构本身，而非可继续调参消除的问题，故如实列为局限性。

（八） 反思闭环消融实验

表 6 展示了反思闭环的消融结果。反思机制在 9/10 种子下正确触发，平均 F1 从 0.32 ± 0.20 提升至 0.84 ± 0.03 ，增益 $+0.51 \pm 0.19$ 。方差从 0.20 降至 0.03，证明反思有效稳定了系统输出质量。

多次迭代实验（max_iter=3/4）表明，1 次重试即可收敛（F1 从 0.30 升至 0.86），额外迭代不再提升，说明反思闭环在首次降级后已足够。

表 6: 反思闭环消融（10 seeds, cross=0.2）

指标	无反思	有反思
平均 F1	0.3228	0.8353
标准差	0.199	0.029
最小 F1	0.3043	0.7674
最大 F1	0.7267	0.8616
反思增益	—	+0.5124±0.1884
触发率	—	9/10




图 7: 反思闭环消融（10 seeds, cross=0.2）。平均 F1 由 0.32 提升至 0.84，标准差由 0.20 降至 0.03，反思显著稳定系统输出质量。

（九） 置信度门控消融实验

构造 5 个混合置信团伙（3 真 + 2 假）验证门控效果：有门控时误冻率 0.25，无门控时 0.40，门控降低误冻率 37.5%。门控正确拦截了低置信假团伙（confidence=0.35 < 0.5），但无法拦截高置信假团伙（confidence=0.75 ≥ 0.5）——这是 4 因子手工加权的已知局限。

（十） 门控系数敏感性分析

为检验手工权重的稳健性，在代表性团伙集合（3 真 + 2 假，含”高规模无资金回流”难例）上，对四因子权重做多方案扫描与蒙特卡洛扰动（±0.05，200 次），并扫描门控阈值：

- **权重扰稳健:** 200 次扰动下误冻率 0.20±0.00、漏冻率 0.20±0.00，说明系数对噪声不敏感；
- **结构局限:** 所有方案均无法拦截”高规模无资金回流”假团伙（误冻率恒为 0.20），因其由权重结构决定而非自适应学习所得；

- **阈值权衡**：提高门限可降低误冻率（ $\text{gate}=0.6$ 时误冻率降至 0.0），但代价是漏冻率上升（中等置信真团伙被放行），呈典型 **trade-off**。

结论：门控系数可由强化学习/监督学习替代以突破该结构性局限，列为未来工作。

（十一） 外部验证

在 AMLSim 小样本（12 环 $\times$ 12 账户）上，Louvain 完美聚类（ $F1=1.0$ ），KMeans（ $F1=0.11$ ）和 GraphSAGE（ $F1=0.14$ ）均失效，说明结构清晰的账户子图中社区发现已足够，GNN 嵌入无增量价值。

诚实标注 需特别指出：HAN 在困难场景 $F1=0.9154$ （10 次随机种子实验均值）源于合成案件，而非真实案卷数据。真实 AMLSim 大规模数据（43,614 账户 / 1,305 环）上所有方法 $F1 \approx 0.002^{[13]}$ ，case 中心方法在账户中心任务上失效——这恰恰证明了”案件级异构图”的设计动机：正确的研判层级是案件而非裸账户。本文方法在真实案件数据上的直接验证为后续工作。

真实公开图上的盲扫复现（Elliptic） 为以真实（非合成）公开数据进一步核验，本文引入 Elliptic Bitcoin 反洗钱数据集^[14]（203,769 笔真实比特币交易，含 illicit/licit 标注）。取最大连通分量下采样至 3,000 节点（其中 2,147 有标签），以单元路径（tx-tx）运行与主实验完全相同协议的 HAN/RGCN/GAT，并对比特特征 KMeans 与 Louvain。结果与 AMLSim 大规模结论完全一致：**盲扫设定下全部方法失效**（HAN $F1_{\text{illicit}}=0.016$ ，RGCN=0.018，GAT=0.015，KMeans=0.013，Louvain=0.154；NMI 均 < 0.01 ）。真实图上的这一结果，恰与前述判断一致：在欺诈占比极低的真实交易网络上，问题瓶颈不在编码器（HAN/RGCN/GAT 无一幸免），而在任务设定本身——由此引出 §（十二）的扩线设定。需明确区分：Elliptic 为真实交易图而非公安案卷，其结果仅可作为外部有效性的旁证，并不等同于”真实警务数据验证通过”。

（十二） 扩线设定下的账户中心 GNN 验证

前述实验均以”案件”为中心构建异构图；为检验方法在”账户中心”任务下的实战适应性，本节采用贴近真实反诈工作流的**扩线（refinement）**设定：给定少数锚点账户（如 AML 告警或报案线索），在其 k 跳嫌疑邻居子图内恢复同伙团伙，而非在全体账户上盲扫。

合成信号账户集 生成每环带独立金额签名的合成账户交易数据（背景账户 + 20 个资金环），在跨团伙拓扑噪声 $\text{cross_talk} \in \{0.25, 0.75\}$ 下比较原始特征 +KMeans、未训练 GNN、训练后 GNN 与 Louvain 在嫌疑子图上的环恢复 F1（表 7）。结果显示：训练后 GNN 在多数设定下仅略优于未训练 GNN 与原始特征基线（5 seed 均值 0.14–0.18，优势有限）；但在结构仍较清晰的子图上，纯拓扑 Louvain 与训练后 GNN 处于同一量级——说明 GNN 的增量价值在“拓扑受扰或不完整”时方显著，而非自动优于经典社区发现。

AMLSim 真实样本 在公开合成基准 AMLSim 账户中心（canonical: 1305 个洗钱环、10,819 个涉案账户、约 4.4M 笔交易）上，于 §（十一）同款真实 `ground_truth` 下实跑扩线设定（锚点 k 跳嫌疑子图）：训练后 GNN 的 F1 仅约 0.003，Louvain 约 0.11，与盲扫全图基线（ $F1 \approx 0.002$ ）处同一量级，并未因扩线而显著改善。文献中常见的“扩线后 GNN 0.78 / Louvain 0.82”多源于以拓扑连通分量定义团伙标签、再聚类恢复该标签的退化评测（标签与所用特征同源），不构成独立的真实团伙恢复验证；本文采用行为学标注的 `ground_truth`，更贴近实战且结果更保守。

表 7: 扩线设定下的团伙恢复 F1（合成嫌疑子图 5 seed 均值 $\pm \text{std}$ / AMLSim 真实样本 canonical 实跑）。AMLSim 列为本工作在真实 `ground_truth` 下的独立复现（GNN 0.003 / Louvain 0.11），文献常见的 0.78/0.82 源于退化评测、不可复现。

方法	合成 $\text{ct}=0.25$	合成 $\text{ct}=0.75$	AMLSim 样本
原始特征 +KMeans	0.116 ± 0.016	0.176 ± 0.006	0.004
未训练 GNN+KMeans	0.111 ± 0.015	0.154 ± 0.020	—
训练后 GNN+KMeans	0.140 ± 0.020	0.183 ± 0.017	0.003
Louvain（拓扑）	0.470 ± 0.032	0.192 ± 0.011	0.111




图 8: 扩线设定下的团伙（资金环）恢复 F1（与表 7 对应）。合成子图上 Louvain 与训练后 GNN 同量级；AMLSim 真实样本（canonical ground_truth 实跑）上 GNN 与 Louvain 仍处盲扫量级，并未因扩线而提升两个数量级，文献 0.78/0.82 系退化评测。

真实 Elliptic 图上的扩线复现 在真实 Elliptic 图^[14]上进一步复现该设定迁移：以 10 个 illicit 锚点（模拟 AML 告警先验）取 2 跳嫌疑子图（5 次独立试验，子图 80–330 节点，子图内 illicit 占比升至 0.59 ± 0.06 ），二类恢复 $F1_{\text{illicit}}$ 为：特征 KMeans 0.720 ± 0.026 、HAN 0.646 ± 0.079 、Louvain 0.557 ± 0.114 ——相对盲扫（ ≈ 0.016 ）提升约 40 倍。真实图证据再次确认：**扩线设定修正本身是数量级增益的来源**；且在该真实子图上特征基线强于 GNN 与社区发现，与合成实验的诚实结论（§（三））相互印证——GNN 并非在一切设定下自动占优。

五 讨论

（一） 机制分析：为什么”案件级异构 + 双通道”有效

综合实验结果，可以从机制层面回答三个问题。**第一，为什么必须建模异构关系？** GraphSAGE 在同构假设下发生表示塌缩（Hard $F1=0.30$ ），而 HAN 保持 $F1 \geq 0.91$ ，说明案件数据中 account/perpetrator/type/text 等多类型实体及其多类型关系是团伙信号的主要载体，忽略异构性会丢失关键判别信息。**第二，为什么需要双通道？** 合成实验中，当跨团伙干扰 cross 增大时，结构通道（资金拓扑）被噪声污染，而文本通道（话术语义）保持稳定——HAN 的语义注意力能自动降低被污染元路径的权重，这是其在 cross=0.4 下仍保持 $F1=0.875$ 的原因。**第三，为什么反思闭环能稳定输出？** 反思消融显示，无反思时失败场景 $F1$ 波动高达 ± 0.20 ，有反思后降至 ± 0.03 ——反思机制本质上是把”模型可能出错”这一不确定性显式纳入流程，通过降级与重算规避单点失效。

（二） 诚实标注：合成数据与真实数据的边界

需要明确的是，本文主实验基于可复现的合成案件数据，而非真实案卷数据。合成数据的一个固有局限是：案情特征（金额、话术文本）本身携带强团伙信号，导致强特征基线（KMeans、Semantic）在部分场景下与 HAN 持平甚至反超。因此，本文对 HAN 的定位是审慎的：**HAN 在同协议图神经基线（RGCN/GAT/GraphSAGE）与资金链社区发现中最优，但在特征信号充分的合成场景下并不全面超越强特征基线。**HAN 的预期增量场景是特征缺失或被伪造而结构线索保留的真实案件——这需要在真实警务数据上进一步验证（列为未来工作）。

外部验证进一步揭示了反诈 GNN 的增量边界：在欺诈占比极低的裸账户网络上盲扫全败（瓶颈在任务设定而非编码器），而锚点驱动的扩线设定可将可恢复性提升约两个数量级。这一结论对真实部署有直接指导意义：应优先采用“案件串并 → 账户扩线”的工作流，而非“全图盲扫”。同时需强调，Elliptic 为真实交易图而非公安案卷，其结果仅可作为外部有效性的旁证，不构成“真实警务数据验证通过”。

（三） 与反诈治理的结合：从“技防”到“人防 + 技防”

反诈治理需要“人防”（公众教育）与“技防”（技术研判）协同。已有实证研究表明，反诈反诈教育能显著提升公众的防范行为，且这一影响部分通过“风险感知 → 反诈意愿”的链式中介实现^[23]。本文系统从两个层面与这一治理框架衔接：其一，系统输出的团伙画像（作案话术模板、资金链路特征）可反哺反诈教育内容设计，使宣传素材从“通用提醒”升级为“基于真实团伙手法的精准提示”，提升公众风险感知的针对性；其二，系统的可解释研判结论（每条并案可追溯到具体共享账户、相似话术）为民警向公众开展警示宣传提供了实证素材，形成“技术发现 → 教育干预 → 行为改变”的闭环。这一结合方向为后续工作提供了空间，本文暂不展开。

（四） 局限性

本文工作存在以下局限：（1）主实验基于可复现合成案件数据（按真实警情形态自建），真实警务数据上的端到端验证待后续合作获取；（2）门控系数为手工启发式权重（0.30/0.20/0.20/0.30），敏感性分析表明其结构性上限在于难以识别“高规模无资金回流”型假团伙，未来可引入监督/强化学习突破；（3）反思策略为启发式规则（质量低则关 GNN），非学习型策略；（4）共识伪标签半监督在干净与轻

噪场景下增量有限甚至略低于规则，其价值集中于重噪、碰撞与大案量场景；增量匹配在重噪场景因“宁缺毋滥”门控主动牺牲召回，对无账户案件依赖攒批机制补回，存在滞后；（5）AMLSim 与 Elliptic 的外部验证暴露出账户中心任务“盲扫 vs 扩线”的设定瓶颈：训练后 GNN 在结构清晰的嫌疑子图中未显著优于 Louvain，其增量价值需在拓扑受扰或不完整场景进一步验证。

六 结论与展望

FraudLens 将多智能体编排与 HAN 相融合，形成案件级串并案与账户级扩线的两级研判闭环，并在统一的反思编排与工程化合规底座下实现自愈式重算与可审计冻卡决策。合成数据实验表明：案件级 HAN 在困难场景下 $F1=0.9154$ （10 次随机种子均值），优于同协议异构图基线 RGCN/GAT；LangGraph 反思闭环将失败场景 $F1$ 从 0.3228 提升至 0.8353（增益 +0.5124）；共识伪标签半监督在重噪场景将 $F1$ 提升至 0.949，增量匹配在轻噪大规模场景反超全量重算（+0.083），语义注意力权重分析为研判结论提供了可解释依据。工程上，系统实现了 RBAC 鉴权、审计追踪、多级降级链与数据不出域。在账户中心任务下，锚点驱动的扩线设定将 AMLSim 与真实 Elliptic 图上的可恢复性由盲扫 $F1 \approx 0.002$ 提升约两个数量级，揭示了反诈 GNN 的关键瓶颈在任务设定而非编码器，为真实研判 workflow 提供了可行路径。

未来工作：与公安机关合作获取脱敏真实案件数据；引入强化学习优化门控系数；探索 HAN 向账户中心任务的迁移能力；利用元路径注意力权重构建反诈领域先验知识库，引导少样本/零样本场景下的模型迁移；探索系统输出的团伙画像向反诈教育内容生成的迁移，支撑“技防 + 人防”协同治理。

参考文献

- [1] Johannessen F, Jullum M. Finding money launderers using heterogeneous graph neural networks[PP/OL]. arXiv (2023) [2026-07-31]. <https://arxiv.org/abs/2307.13499>. DOI:10.48550/arXiv.2307.13499.
- [2] 庄华, 马忠红. 电信网络诈骗犯罪预警的失灵与优化[J/OL]. 情报杂志, 2025, 44 (2): 116-123. DOI:10.3969/j.issn.1002-1965.2025.02.016.
- [3] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]// International conference on learning representations (ICLR) . 2017.
- [4] Hamilton W L, Ying R, Leskovec J. Inductive representation learning on large graphs[C]// Advances in neural information processing systems (NeurIPS) . 2017.
- [5] Zhang Jun, Lu Jianguang, Tang Xianghong. Two-stage GNN-based fraud detection with

- camouflage identification and enhanced semantics aggregation[J/OL]. *Neurocomputing*, 2024, 570: 127108. DOI:[10.1016/j.neucom.2023.127108](https://doi.org/10.1016/j.neucom.2023.127108).
- [6] 石拓, 曾昭龙, 韩娜. 融合大语言模型和语义聚类的电信网络诈骗引流话术文本分析[J/OL]. *情报杂志*, 2025, 44 (10): 105-112. DOI:[10.3969/j.issn.1002-1965.2025.10.013](https://doi.org/10.3969/j.issn.1002-1965.2025.10.013).
- [7] 邓翠艳, 齐小刚. 基于 Transformer 及多任务学习的电信网络诈骗识别[J/OL]. *应用科技*, 2024, 51 (5): 256-262. DOI:[10.11991/yykj.202406012](https://doi.org/10.11991/yykj.202406012).
- [8] 杨泽铎, 沙晶莹. 基于犯罪脚本的电诈话术分析与预防研究[J]. *河北公安警察职业学院学报*, 2025, 25 (2): 19-23.
- [9] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[C]//International conference on learning representations (ICLR). 2018.
- [10] Dou Yingtong, Liu Zhiwei, Sun Li, et al. Enhancing graph neural networks by a label propagation algorithm for fraud detection[C/OL]//Proceedings of the ACM international conference on information & knowledge management (CIKM). 2020: 2589-2592. DOI:[10.1145/3340531.3412716](https://doi.org/10.1145/3340531.3412716).
- [11] Sha Qiuwu, Tang Tengda, Du Xinyu, et al. Detecting credit card fraud via heterogeneous graph neural networks with graph attention[PP/OL]. *arXiv* (2025) [2026-07-31]. <https://arxiv.org/abs/2504.08183>. DOI:[10.48550/arXiv.2504.08183](https://doi.org/10.48550/arXiv.2504.08183).
- [12] Wang Xiao, Ji Houye, Shi Chuan, et al. Heterogeneous graph attention network[C/OL]//The world wide web conference (WWW). 2019: 2022-2032. DOI:[10.1145/3308558.3313562](https://doi.org/10.1145/3308558.3313562).
- [13] Weber M, Domeniconi G, Chen Jie, et al. Scalable graph learning for anti-money laundering: a first look[PP/OL]. *arXiv* (2018) [2026-07-31]. <https://arxiv.org/abs/1812.00076>. DOI:[10.48550/arXiv.1812.00076](https://doi.org/10.48550/arXiv.1812.00076).
- [14] Weber M, Domeniconi G, Chen Jie, et al. Anti-money laundering in bitcoin: experimenting with graph convolutional networks for financial forensics[PP/OL]. *arXiv* (2019) [2026-07-31]. <https://arxiv.org/abs/1908.02591>. DOI:[10.48550/arXiv.1908.02591](https://doi.org/10.48550/arXiv.1908.02591).
- [15] 花璐璐. 基于 SOAR 的新一代网络安全运营中心建设探究[J]. *网络安全技术与应用*, 2025 (9).
- [16] 束维国. 基于安全编排自动化与响应技术在网络安全应急响应中的应用探索[J/OL]. *现代工业经济和信息化*, 2022 (8): 112-114. DOI:[10.16525/j.cnki.14-1362/n.2022.08.043](https://doi.org/10.16525/j.cnki.14-1362/n.2022.08.043).
- [17] Shinn N, Cassano F, Gopinath A, et al. Reflexion: language agents with verbal reinforcement learning[C]//Advances in neural information processing systems (NeurIPS). 2023.
- [18] 江颀, 等. 基于大语言模型的多智能体自动渗透测试框架构建与评估[J]. *信息安全研究*, 2026.
- [19] LangChain. LangGraph: building stateful multi-agent applications with LLMs[EB/OL]. (2024) [2026-07-31]. <https://github.com/langchain-ai/langgraph>.
- [20] 张豈明, 等. Lpaa: 基于 LangGraph 的教案自动生成智能体[J]. *现代教育技术*, 2025.
- [21] BAAI. BGE: BAAI general embedding[EB/OL]. (2023) [2026-07-31]. <https://huggingface.co/BAAI/bge-large-zh-v1.5>.

- [22] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C/OL]//European semantic web conference (ESWC) . 2018: 593-607. DOI:[10.1007/978-3-319-93417-4_38](https://doi.org/10.1007/978-3-319-93417-4_38).
- [23] 江海洋. 防诈反诈教育对公众网络诈骗风险防范行为影响研究——基于江西省的问卷调查[D]. 南昌: 江西农业大学, 2025.