

基于多智能体编排与异构图注意力网络的反诈团伙研判系统

摘要： 电信网络诈骗团伙控制大量银行账户编织资金转移网络，人工串并案研判效率有限。本文提出反诈团伙研判系统，以“案件级串并案、账户级扩线”构成两级研判闭环，核心检测器采用异构注意力网络，在含五条元路径的异构资金链图上以语义注意力自适应融合资金拓扑与话术文本两路信号，并由反思编排驱动自愈式重算。合成案件实验显示：困难场景下异构注意力网络 F1 达 0.9154（10 次随机种子均值），反思闭环把失败场景 F1 从 0.32 拉回 0.84，置信度门控把误冻率从 0.40 降到 0.25；锚点驱动的扩线把可恢复性提升约两个数量级。

关键词： 反诈；图神经网络；异构注意力网络；多智能体；反思闭环

1 引言

电信网络诈骗已是发案最多、上升最快的犯罪类型之一。一个团伙往往同时控制大量手机号和银行账户，单凭单笔交易还原不了完整资金链路。反诈治理沿两条路径走：一条是面向公众的防范教育，已有实证研究表明，反诈教育能显著提升公众防范行为，且部分通过“风险感知到反诈意愿”的中介实现[1]；另一条是案发后的技术研判，靠串并案和资金链路分析锁定团伙，这一路长期依赖人工，效率和覆盖面都有限[2]，既有预警系统还受数据壁垒与模型失灵困扰[3]。

串并案研判的技术难点有三类方法摆在那：基于规则的串并靠办案人员经验，难以规模化；KMeans、HDBSCAN 这类浅层聚类只用了浅特征，建模不了账户之间的复杂关联；图神经网络能利用图结构[4,5]，但针对欺诈检测的图方法多假设同构节点[6]，建不了案件、账户、违法者多类实体并存的关系。话术层面已有大语言模型加语义聚类的探索[7]，但话术相似不等于资金关联，单靠话术把案件归并，聚类结果撑不起冻卡决策。

本文针对三个具体问题下手：案件数据天然异构，一个案件连着账户、违法者、类型、地域、话术多类实体；真实警情又脏又持续进来，账户缺失、号码打码、话术高频微调，单靠资金或单靠话术都不可靠；冻卡决策直接影响公民财产权利，结论必须可审计、可追溯。据此构建的系统把两级研判架构、异构双通道融合、反思编排和工程底座整合成一套可落地研判工具，并通过外部数据诚实量化了方法的增量边界。

2 系统总体架构

系统采用分层架构，自上而下是交互层、决策协同层、数据模型层（图 1）。逻辑上构成两级研判闭环：案件级串并案（一级）用异构注意力网络在案件异构图上聚合关联案件；账户级扩线（二级）以一级输出的团伙内关键收款账户为锚点，在账户交易子图上沿资金链上下游还原同伙。一级的输出直接作为二级的输入，形成“案件聚类到账户扩线”的完整链路，契合民警“先串并案锁定团伙、再拿已知账户扩线追查”的真实工作流。

交互层面向一线研判人员，Web 界面呈现团伙关系图、统计报表和画像卡。决策协同层是核心，接口层之下由状态图编排多智能体反思闭环（见 3.3 节）。数据模型层坚持数据不出域：关系数据存本地库，图和向量是由源数据可重建的派生视图，话术语义嵌入由本地语义模型推理，全程不依赖外部接口上传案件数据。




图1 系统三层架构

3 核心方法

3.1 两级研判闭环

两级闭环把"先粗后细"串成一条流水线（图2）。案件级以案件为节点建异构图，用异构注意力网络聚类，输出团伙锚点，即经过质量校验的团伙内关键收款账户。账户级拿到锚点后，在图神经网络的k跳嫌疑子图上定向扩线，沿资金链上下游还原同伙网络，而不是在全体账户上盲扫；锚点周边小范围子图上的定向扩线，计算量小、命中率高，这正是"先串并案、再扩线追查"的反诈 workflow。新案件持续进来时，案件级重新聚类、锚点动态更新，两级循环往复。




图2 两级研判闭环：案件级串并案输出团伙锚点，账户级扩线沿资金链还原同伙

3.2 异构注意力网络与双通道融合

以案件为中心构建含五类节点、五条元路径的异构资金链图：共享账户边（两案共用一个收款账户）、共享违法者边（涉及同一违法者）、案件类型边（同属刷单返利、杀猪盘等类型）、城市边（同地域作案）以及话术语义边（两案话术的语义嵌入余弦相似度不低于0.5）。前四条元路径归入结构通道，刻画案件间客观关联；话术边单独成文本通道，刻画诈骗话术的模式相似性（图3）。

双通道的设计动机来自真实案情：团伙为规避追踪会刻意拆分收款账户、跨地域流窜、轮换角色，结构通道信号被不断弱化；但同一犯罪模式的话术脚本，比如刷单返利、杀猪盘的开场白，会在不同案件里反复出现。文本通道因此成为结构受扰时的保留信号。异构注意力网络对每条元路径做节点级注意力聚合，再由语义级注意力学习各元路径权重，自动决定资金拓扑和话术文本谁更可信，并在不同团伙演化阶段自适应组合两路证据。

模型训练采用免标签的图对比学习：对元路径邻接做边丢弃、对节点特征做掩码增广，构造同一批案件的两个视图，用对比损失拉近同一案件两个视图的嵌入、推远不同案件。预训练不需要团伙标签，在案件标注稀缺的真实场景下仍能学到可迁移的案件表示；预训练完成后，案件嵌入向量标准化后进聚类完成团伙归并。




图3 资金链双通道设计：结构通道与文本通道经语义注意力融合，支撑案件级团伙聚类

3.3 反思闭环编排与置信度门控

研判 workflow 由状态图编排为五个节点：规划、预处理、分析、聚类、反思（图4）。反思节点给每次研判结果打质量分，收敛判定由三个条件加权合成：团伙数是否足够、分析结论是否可信、质量分是否达标。整体分低于 0.6 且重试次数未到上限时，触发降级调整后回连分析节点重算，具体手段包括关闭图神经网络回退到规则聚类、调细聚类粒度。反思借鉴言语强化思路，把“模型可能出错”这个不确定性显式放进流程，用真实重算替代“重跑一遍装饰”。

团伙检测完成后，系统为每个团伙算经验加权置信度，权重由四个因子按手工设定：团伙规模、涉案金额、关联账户数、资金回流闭环标志。置信度不低于 0.5 的团伙给出“建议冻结”，低于 0.5 的落入“待人工复核”。所有门控结论落库审计表，支持追溯。




图4 LangGraph 反思闭环编排：反思节点经条件边决定回连重算或输出结果

4 实验与结果

4.1 实验设置

实验采用可复现的合成案件数据：默认 5 个团伙、每个团伙 8 起案件，共 40 案；跨团伙账户共享概率 0 到 0.4 对应由易到难的干扰场景。评价指标用成对宏平均 F1 和误冻率。基线包括 KMeans、HDBSCAN、纯语义聚类、Louvain 资金链聚类、GraphSAGE，以及同协议实现的 RGCN 和 GAT 两个异构基线——它们与本文模型共享完全相同的异构图、元路径邻接、文本通道和对比学习预训练协议，唯一差异在聚合与注意力机制，保证公平比较。需要先说明：全部实验基于合成案件而非真实案卷，真实数据的端到端验证列为后续工作。

4.2 主实验：基线对比

表 1 给出主实验结果。异构注意力网络在干净场景 F1 达到 1.00，困难场景 0.9154；同构 GraphSAGE 因建模不了多类型实体关系发生表示塌缩，困难场景只有 0.30。这说明案件图上异构注意力是必要基础。同协议异构基线对比中，本文模型总体 F1 为 0.918，高于 GAT 的 0.879 和 RGCN 的 0.852；配对检验显示对 RGCN 的优势在干净与强干扰场景下显著。语义级注意力对元路径重要性的自适应加权，确实优于无差别均值融合。

表 1 合成数据基线对比（10 次随机种子均值±标准差）

方法	干净场景 F1	困难场景 F1
KMeans	0.9122±0.1075	0.9368±0.1363
HDBSCAN	0.8888±0.1046	0.8966±0.1298
纯语义聚类 (BGE)	0.9076±0.1134	0.9367±0.1331
Louvain 资金链聚类	0.8884±0.0911	0.8616±0.0874
GraphSAGE	0.4061±0.2127	0.3043 (塌缩)
本文模型 (HAN)	1.0000±0.0000	0.9154±0.1214

注：F1 为成对宏平均；干净场景对应无跨团伙干扰，困难场景对应跨团伙干扰 0.2。

需要如实交代一点：困难场景下强特征基线 KMeans 和纯语义聚类的均值与本文模型同量级甚至反超。合成案情本身的特征（涉案金额、话术文本）已携带强团伙信号，拓扑干扰引入后，“忽略图结构”反倒规避了结构噪声。因此审慎的结论是：本文模型在图神经基线内部最优，但并非在一切场景全面超越强特征基线；它的预期增量场景是特征缺失或被伪造、结构线索保留的真实案件。

4.3 反思闭环与置信度门控消融

图 5 与表 2 给出反思闭环的消融结果。反思机制在 10 次种子实验里 9 次正确触发，平均 F1 从 0.32 提升到 0.84，标准差从 0.20 压到 0.03。方差大幅收缩说明反思的主要价值不是提分，而是把输出质量钉在稳定区间。多次迭代实验显示 1 次重试即可收敛，额外迭代不再提升。




图 5 反思闭环消融（10 次种子，跨团伙干扰 0.2）。平均 F1 由 0.32 提升至 0.84，标准差由 0.20 降至 0.03；误差线表示标准差（n=10）

表 2 反思闭环消融（10 次种子，跨团伙干扰 0.2）

指标	无反思	有反思
平均 F1	0.3228	0.8353
标准差	0.199	0.029
最小 F1	0.3043	0.7674
最大 F1	0.7267	0.8616
反思增益	—	+0.5124±0.1884
触发率	—	9/10

门控消融构造 5 个混合置信团伙（3 真 2 假）：有门控时误冻率 0.25，无门控时 0.40，降低 37.5%。门控拦住了低置信假团伙，但拦不住高置信假团伙，这是四因子手工加权的已知局限，可监督学习替代列为未来工作。

4.4 外部验证与扩线设定

外部验证用两个公开基准：AMLSim 合成洗钱数据和真实 Elliptic 比特币交易图。两个数据集上的结论一致：在欺诈占比极低的裸账户网络上做全图盲扫，所有方法全部失效，F1 约 0.002。这暴露了反诈图神经网络的真实瓶颈——问题不在编码器，所有编码器无一幸免，而在任务设定本身。

据此改为扩线设定：给定少数锚点账户，在其 k 跳嫌疑子图内恢复同伙，而非全体账户盲扫。在真实 Elliptic 图上取 10 个非法交易锚点、2 跳子图后，恢复 F1 从盲扫的 0.016 提升到 0.72，提升约 40 倍。文献中常见的“扩线后 F1 达到 0.78”多源于以拓扑连通分量定义团伙标签的退化评测，标签与所用特征同源，不构成独立验证；本文用行为学标注的真实标签，结果更保守、更贴近实战。扩线提升来自任务设定修正本身，而不是某个编码器更聪明。

5 讨论与局限

三个机制问题值得回答。为什么必须建模异构关系：GraphSAGE 在同构假设下塌缩到 0.30，而异构注意力网络保持 0.91 以上，说明账户、违法者、话术等多类型关系是团伙信号的主要载体。为什么需要双通道：跨团伙干扰增大时，资金拓扑被噪声污染，话术文本保持稳定，语义注意力自动调低被污染元路径的权重。为什么反思能稳定输出：反思把“模型可能出错”显式纳入流程，通过降级与重算规避单点失效，方差从 0.20 压到 0.03。

局限有三条：主实验基于合成数据，真实警务数据端到端验证待后续合作获取；门控系数是手工启发式权重，结构性上限在于识别不了“大规模无资金回流”型假团伙；反思策略是规则而非学习型策略。外部验证同时提示，图神经网络在结构清晰的子图上并不自动优于经典社区发现，其增量价值需要在拓扑受扰或不完整场景中验证。

6 结论与展望

系统把多智能体编排与异构注意力网络结合起来，形成案件级串并案、账户级扩线的两级研判闭环，在统一反思编排与工程底座下实现自愈式重算和可审计的冻卡决策。合成数据实验验证了异构双通道融合的有效性，反思闭环把失败场景 F1 从 0.32 提升到 0.84；外部验证揭示了反诈图神经网络的关键瓶颈在任务设定而非编码器，为真实研判 workflow 提供了可行路径。

未来工作：与公安机关合作获取脱敏真实案件数据；用强化学习优化门控系数；把元路径注意力权重沉淀为反诈领域先验，支撑少样本场景迁移；把团伙画像反哺反诈教育内容，支撑“技防加入防”协同治理。

参考文献

- [1] 江海洋. 反诈反诈教育对公众网络诈骗风险防范行为影响研究——基于江西省的问卷调查[D]. 南昌：江西农业大学，2025.
- [2] Johannessen F, Jullum M. Finding money launderers using heterogeneous graph neural networks[EB/OL]. arXiv:2307.13499, 2023.
- [3] 庄华，马忠红. 电信网络诈骗犯罪预警的失灵与优化[J]. 情报杂志，2025，44(2)：116-123.
- [4] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[C]//ICLR. 2017.
- [5] Hamilton W L, Ying R, Leskovec J. Inductive representation learning on large graphs[C]//NeurIPS. 2017.
- [6] Dou Y, Liu Z, Sun L, et al. Enhancing graph neural networks by a label propagation algorithm for fraud detection[C]//CIKM. 2020：2589-2592.
- [7] 石拓，曾昭龙，韩娜. 融合大语言模型和语义聚类的电信网络诈骗引流话术文本分析[J]. 情报杂志，2025，44(10)：105-112.
- [8] Wang X, Ji H, Shi C, et al. Heterogeneous graph attention network[C]//WWW. 2019：2022-2032.
- [9] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]//ESWC. 2018.
- [10] Velickovic P, Cucurull G, Casanova A, et al. Graph attention networks[C]//ICLR. 2018.
- [11] BAAI. BGE：BAAI general embedding[EB/OL]. <https://huggingface.co/BAAI/bge-large-zh-v1.5>, 2023.

- [12] Weber M, Chen J, Suzumura T, et al. Anti-money laundering in bitcoin: experimenting with graph convolutional networks for financial forensics[C]//KDD Workshop. 2019.
- [13] Shinn N, Cassano F, Gopinath A, et al. Reflexion: language agents with verbal reinforcement learning[C]//NeurIPS. 2023.